

# 4 Теоретические задачи

## 4.1 наивный байес и центроидный классификатор

$$\begin{aligned} \underset{y}{\operatorname{argmax}} \left( \prod_{k=1}^n \frac{1}{2\pi\sigma^2} e^{-\frac{(x^{(k)} - \mu_{y_k})^2}{2\sigma^2}} Pr(y) \right) = \\ = \underset{y}{\operatorname{argmin}} \left( \sum_{k=1}^n (x^{(k)} - \mu_{y_k})^2 \right) \end{aligned}$$

Поскольку  $Pr(y) = \text{const}$ , а максимум оставшейся функции является минимумом аргумента экспоненты, в которой также можно избавиться от константного множителя

**4.2 ROC-AUC случайных ответов** Пусть количество 1 в выборке равно  $k$ , размер выборки  $n$ , тогда:

$$\begin{aligned} \xi_i &= \text{Bern}(p) \\ tp &= \sum_{i=1}^k \xi_i, fp = \sum_{i=1}^{n-k} \xi_i \\ tn &= \sum_{i=1}^{n-k} 1 - \xi_i, fn = \sum_{i=1}^k 1 - \xi_i \end{aligned}$$

Получаем искомые случайные величины:

$$\begin{aligned} FPR &= \frac{fp}{fp + tn} = \frac{\sum_{i=1}^{n-k} \xi_i}{\sum_{i=1}^{n-k} \xi_i + \sum_{i=1}^{n-k} (1 - \xi_i)} = \frac{\sum_{i=1}^{n-k} \xi_i}{n - k} \\ TPR &= \frac{tp}{tp + fn} = \frac{\sum_{i=1}^k \xi_i}{\sum_{i=1}^k \xi_i + \sum_{i=1}^k (1 - \xi_i)} = \frac{\sum_{i=1}^k \xi_i}{k} \end{aligned}$$

взяв математическое ожидание, получим:

$$\mathbb{E}FPR = p$$

$$\mathbb{E}TPR = p$$

Значит средняя точка лежит на диагонали квадрата. Значит площадь в среднем равна  $\frac{1}{2}$